FJFI ČVUT v Praze

Domácí úkol: Thesis Entry Assignment: Neural Networks and the Phase Problem

Jméno: Hugo Sereghy
Datum: 14.10.2026

---

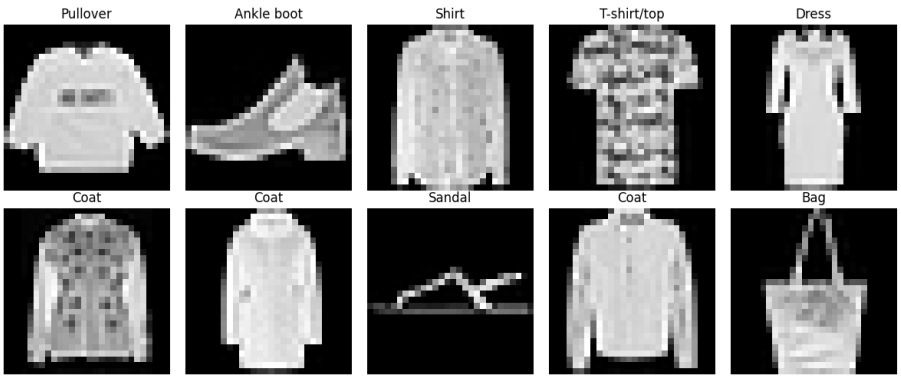
1 Motivace problému

Elektronová mikroskopie je vědecká metoda, používaná k určení atomové struktury materiálů. V X-ray krystalogrfii je krystal ozářen X-ray zářením, jenž je ohýbáno elektrony v krystalech, díky peridoickému uspořádání atomů, poté dostáváme difrakční obrazce ze kterých jsem schopni odečíst intenzity vln.

Problém nastává pokud chceme zreknostruovat reálnou strukturu krystalu, na to potřebujeme jak amplitudy tak fáze fourierových koeficientů, kde amplitudy popisují "sílu"prostorových frekvencí a fáze jak se kombinují v prostoru. Bez informace fáze je pak inverzní fourierova transformace nejednoznačná a různé struktury mohou mít stejné Amplitudy.

2 Data a jejich úprava

Fashion-MNIST je dataset obshaující obrázky oblečení ze stránek zalando. Dataset obshuje 60000 trénovacích a 10000 testovacích obrázků, každý obrázek má rozlišení 28 na 28 pixelů, obrázky jsou černobílé, tak že každý pixel má hodnoty mezi 0 až 255. Obrázky jsou rozděleny do 10 tříd, podle toho který typ oblečení vyobrazují (T-shirt/top, Trouser, Pullover, Dress, Coat, Sandal, Shirt, Sneaker, Bag, Ankle boot).



Obrázek 1: Příklady obrázků z různých tříd datasetu fashion-MNIST.

Obrázky byly převedeny do vektorů s 785 prvky kde první prvek je jena třída do které obrázek patří(0-9) a zbylé prvky jsou hodnoty jednotlivých pixelů(0-255). Hodnoty pixelů byly dále normalizovány na hodnoty z množiny [0,1] a trénovací množina rozdělena na trénovací o 50000 obrázcích a validační o 10000 obrázcích. Jednotlivé mnioziny pak byly rozděleny do batches po 128 obrázcích.

3 MLP a CNN modely

Pro řešení úlohy roztřídění obrázků do příslušných tříd, byly využity metody strojového učení a to modely multilayer perceptron a convolution neural network jejichž výseldky byly vůči sobě porovnány.

3.1 Multilayer perceptron

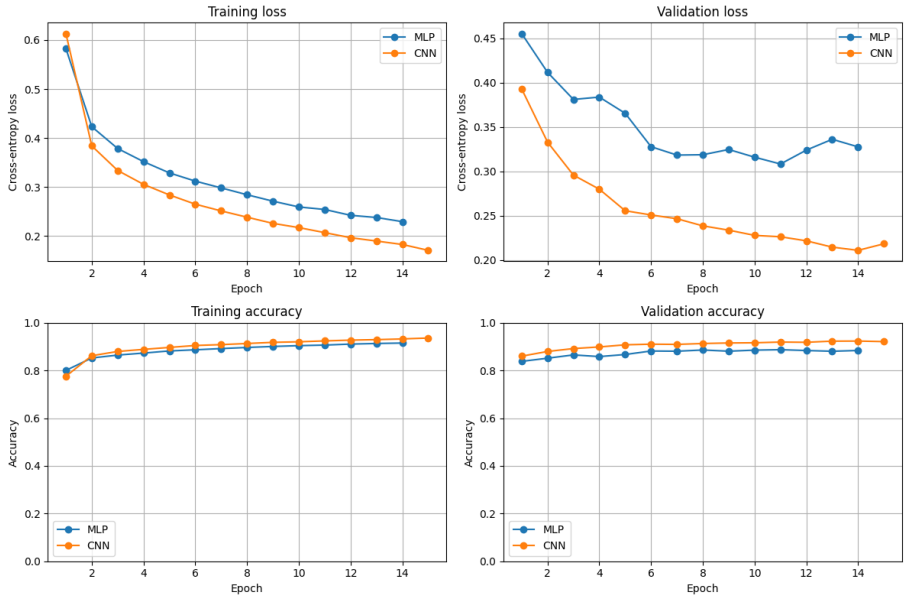
Pro model multi layer perceptron(MLP) na vsupu zadáváme 754 hodnot do 256 neuronů na jejichž výstupu je aktivační funkce ReLU odkud dostáváme 256 vstupů a plně propojenou vrstvu s deseti neurony

klasifikující vstupy do jedné z deseti tříd.

3.2 Convolution neural network

Pro model convolution neural network(CNN) máme na první konvoluční vrstvě 32 feature map o rozměru 28 na 28, na jejichž výstupu je aktivační funkce ReLU, výstupem je matice o velikosti 28 na 28, která je v Max pooling vrstvě převedena na 14 na 14 matici nejvýraznějších prvků ty pak jdou do druhé kovoluční vrstvy s 64 feature mapami s ReLU aktivační funkcí kde Max pooling vrstva převed výstupní matice na tenzor tvaru 7 na 7 na 64 ty převedeme na vektor který dáváme na vstup MLP sítě s 3136 neurony s ReLU aktivační vrstvou a dropout (0,25), kde výstupy plně propojenou vrstvou posíláme na 10 neuronů klasifikující vstupy do 10 třídd.

K učení modelů užíváme backpropagation algoritmus v něm užíváme adam optimalizátoru k upravování vah a loss funkci počítáme podle Crossentropy Loss funkce a ukládáme nejlepší stav vah resp. feature map.

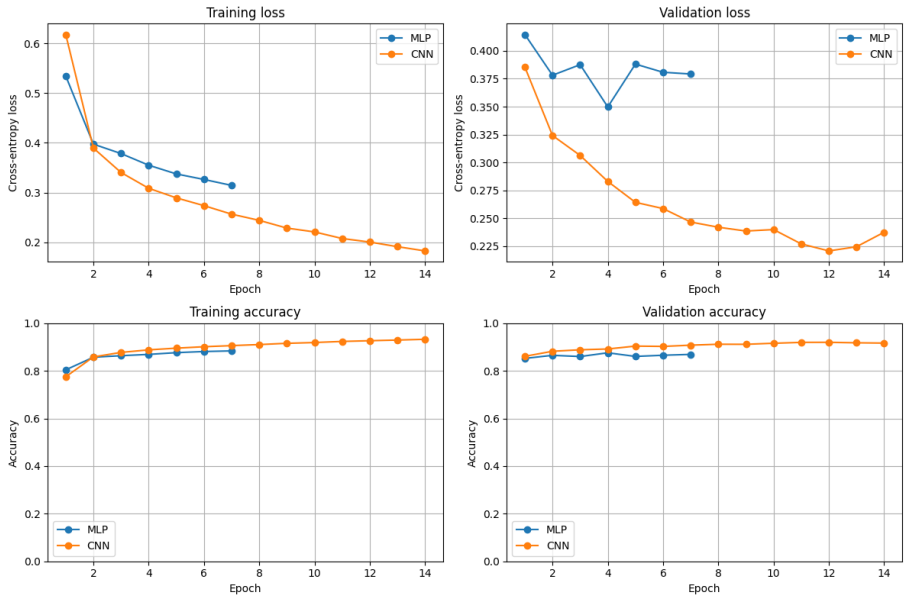


Obrázek 2: MLP a CNN accuracy a loss na testovací a validační množině.

Výsledky na testovací množině accuracy: MLP - 87.57%, CNN - 91.95%.

4 Pokusy na MLP a CNN s původními daty

TBD



Obrázek 3: MLP a CNN accuracy a loss na testovací a validační množině s upravenými hyperparametry.

5 furierovy transformace a CNN

Zavedeme si dvo dimnezionální funkci f(x,y) která bude repreznetovat naše obrázky. Pak pro každý obrázek f(x,y) máme diskrétní fourierovu 2D transformaci zadanou rovnicí

$$F(u,v) = \sum_{x=0}^{27}\sum_{y=0}^{27} f(x,y)e^{-2\pi i(ux+vy)/28}, \tag{1}$$

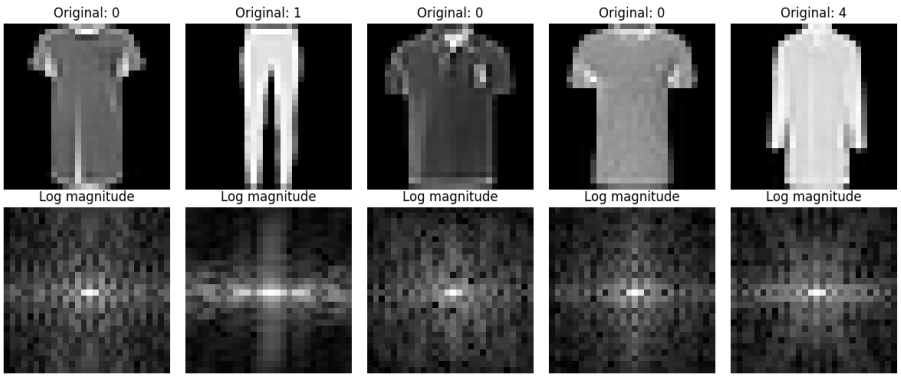
kde u a v indexují horizontální a vertikální prostorové frekvence a i je komplexní jednotka.
Výraz [1] lze přepsat do tvaru

$$F(u,v) = |F(u,v)|e^{i\phi(u,v)}, \tag{2}$$

kde $|F(u,v)|$ je amplituda a $\phi(u,v)$ je funkce amplitudy FT.
Amplituda funkce fourierovy transformace může mít velice odlišné hodnoty proto využijeme vztahu

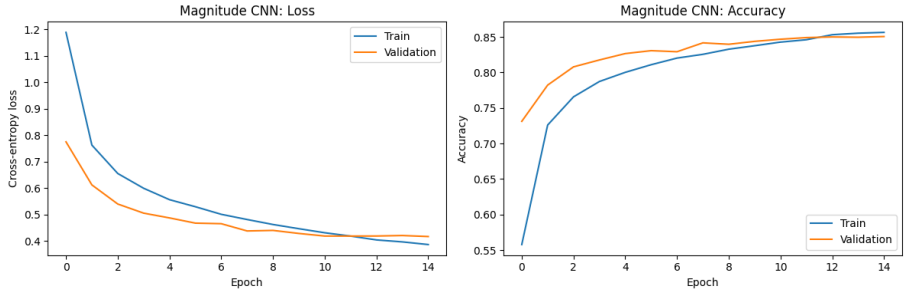
$$M(u,v) = \log(1 + |F(u,v)|), \tag{3}$$

k přeškálování velikostí amplitud okolo 1 toto pomůže učení konvoluční sítě a zjednodušší vizualizaci.
K provedení Fourierovy transformace použijeme 2D Fast Fourier Transform funkci z knihovny pytorch.
Dále zahodíme informace o fázích pro jednotlivé obrázky a zrekonstrujeme obrázky jen podle Amplitud.



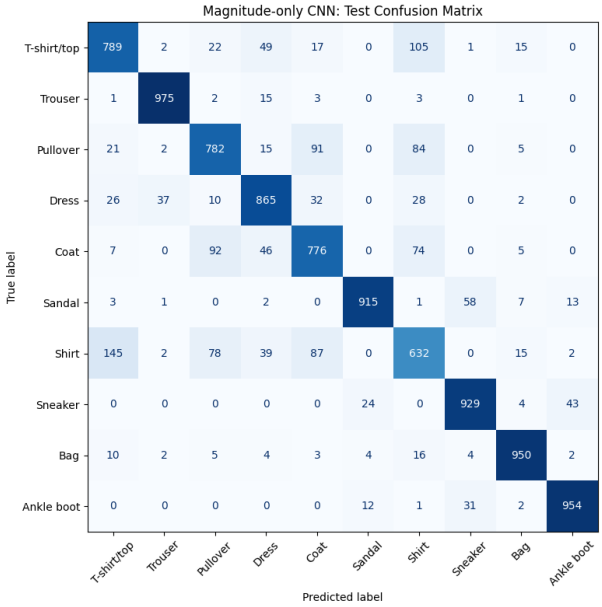
Obrázek 4: Obrázky po fourierově transformaci při které byla ztracena informace o fázi

Poté na obrázcích zrekonstruovaných čistě z amplitud znovu naučíme CNN model a.



Obrázek 5: Accuracy a loss pro CNN model naténovaný na upravených obrázcích

Nakonec klasifikační dovdnosti otestujeme na testovací množině která proběhla fourierovou transformací a byly rekonstruovány obrázky jen z jejich amplitud poté dostaneme na této množině accuracy 85.67%.



Obrázek 6: Confusion matrix testovací množiny upravených obrázků klasifikovaných CNN modelem.

6 Pokus se záměnou fáze

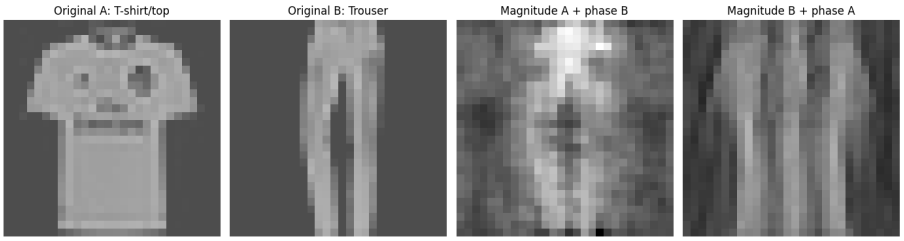
Pokus kde vybereme dva náhodné obrázky A,B a provedeme jejich fourierovy transformace

$$F_A = M_A e^{i\phi_A}, \qquad F_B = M_B e^{i\phi_B} \tag{4}$$

těmto transformacím prohodíme fáze a provedeme inverzní fourierovu transformaci

$$I_{A'} = \mathcal{F}^{-1}(M_A e^{i\phi_B}), \qquad I_{B'} = \mathcal{F}^{-1}(M_B e^{i\phi_A}) \tag{5}$$

otud zpátky dostaneme obrázky, avšak rekonstruované s fází druhého.



Obrázek 7: Obrázky A a B z původní množiny a jejich verze kde při rekonstrukci byly prohozeny jejich fáze.

6.1 Interpretace

Jasně vidíme že obrázky sice jsou jiné od svých originálů A a B ale A' a B' jsou na první pohled rozeznatelné že pocházejí z jiných tříd to je poměrně pozitivní kdybychom na těchto datech chtěli trénovat CNN model.

Obrázky A' a B' jsou velice rozmazané a není z nich jasné z jaké třídy přesně pocházejí to je naopak dosti nešťastná vlstnost pro práci s CNN modely.

Fáze určuje jak jsou komponenty frekvencí posonuty vůči sobě a tak hraje velkou roli při tvorbě ostrých hran a stráta fáze vede k pozorovanému rozmazání obrázku.

Amplitudy popisují sílu a rozmístění prostorových frekvencí a mezi obrázkem A a A' zachovávají informace.

Experiment prezentuje že Amplitudy a fáze popisují sice jiné, ale navzájem komplementární informace.

7 Závěr

Provedené experimenty nám pomohly proniknout do problematiky rekonstrukce obrazu z inverzní fourierovy transformace při ztrátě informace o fázi a jakou roli tento problém hraje v elektonové mikroskopii krystalických struktur a limitace užití základních metod strojového učení při řešení tohoto problému.

Při dalších experimentech by bylo zajímavé natrénovat CNN model na obrázcích z původní množiny dat a poté se pokusit klasifikovat obrázky které proběhly fourierovou transformací a byla odebrána jejich fáze a pozorovat výsledky.

Při dalších experimentech by bylo zajímavé zkoumat opačnou úlohu, kde nebudeme rekonstruovat obrázky bez fáze jen s Amplitudou, ale naopak bez Amplitudy a jen s fází.

Experiment s prohazováním fází mezi obrázky by bylo dobré provéest na více obrázcívh a ostatních třídách a porovnat mezi sebou.

Bylo by vhodné pro hlubší pochopení jakou roli hraje fáze a jakou apmlituda porovnat obrázky kde nebyla zaměněna jejich fáze, ale Amplitudy.

8 Využití AI

Při tvorbě projektu bylo využito nástrujů umělé inteligence, k návrhu struktury projektu, k programování v knihovnách pytorch a matplotlib a jako nástroj pro lepší porozumění teoretickým podkladům. Tvůrce nakládal s nástroji umělé inteligence obezřetně a kontroloval výstupy generované nástroji umělé inteligence.